



مدل های زبانی بزرگ (بهار ۱۴۰۵)

تمرین کامپیوتری چهارم

مهلت ارسال: ۱۴۰۵/۰۳/۲۲

استاد درس: دکتر دوستی

طراحان تمرین:

- نرگس غلامی (narge.gholami@ut.ac.ir)

- علیرضا آخوندی (alireza.akhoundi@ut.ac.ir)

قوانین و ملاحظات

نحوه ارسال تمرین:

- تمامی فایل ها باید در یک فایل فشرده با نام LLM-CA4-StudentID ارسال شوند.
- تمامی کدهای ارسال شده باید امکان اجرای مجدد داشته باشند. اگر تنظیمات خاصی برای اجرا نیاز است، آن را ذکر کنید.
- کدهای ارسال شده باید توسط خودتان اجرا شده باشند و نتایج اجرا در فایل ارسالی مشخص باشد.

رعایت اصول آکادمیک و صداقت علمی:

- این تمرین باید به صورت فردی انجام شود. هرگونه همکاری یا نوشتن تمرین به صورت گروهی ممنوع است.
- در صورت مشاهده تشابه در پاسخ، تمامی افراد درگیر، نمره صفر دریافت خواهند کرد و موضوع به استاد گزارش خواهد شد.

استفاده از ابزارهای هوش مصنوعی:

استفاده از ابزارهایی مانند Copilot، Gemini، ChatGPT و موارد مشابه مجاز است، اما تحت شرایط زیر:

- نحوه استفاده از این ابزارها را در انتهای نوتبوک خود توضیح دهید (ابزارهای استفاده شده، کاربردهای مشخص و موارد مرتبط).

- تمامی پرامپت ها و لینکهای استفاده شده را در انتهای نوتبوک و در یک سلول قرار دهید.
- عدم ارائه این اطلاعات به منزله سرقت علمی محسوب شده و منجر به نمره صفر خواهد شد.

ارتباط با TA ها و پرسیدن سوال:

- دانشجویان میتوانند تمامی سوالات مرتبط به تمرین خود را در گروه درس و یا با ایمیل با TA طراح سوال مطرح کنند.

- در تمامی پرسش ها حتما ایمیل دستیاران ارشد درس باید cc شود.

○ علی رمضانی - ali.ramezani.96@ut.ac.ir

○ علی خرم فر - Khoramfar@ut.ac.ir

مهلت ارسال و جریمه تأخیر:

- امکان ارسال تمرین با تأخیر تا ۲ روز وجود دارد. برای هر روز تأخیر ۱۰ درصد جریمه اعمال میشود.
- تأخیر به صورت ساعتی محاسبه شده و پس از دو روز تأخیر، تمرین پذیرفته نخواهد شد.
- مهلت ارسال عادی این تمرین تا پایان روز ۲۲ خرداد و مهلت ارسال با تأخیر تا پایان روز ۲۴ خرداد می باشد.

تمرین اول: پژوهش یار هوشمند

مقدمه:

مدل های زبانی بزرگ (LLM) در پاسخگویی به سوالات متنی و تولید محتوای نظیر هستند؛ اما زمانی که با سه چالش بزرگ روبه رو می شوند، عملکرد آن ها به شدت افت کرده یا دچار توهم (Hallucination) می شوند:

۱. محدودیت زمانی دانش (Knowledge Cutoff): عدم دسترسی به اطلاعات زنده و اخبار روز دنیا.
 ۲. ضعف در تفکر منطقی و ریاضی: ناتوانی در انجام محاسبات عددی دقیق به دلیل ماهیت احتمالات متنی.
 ۳. مسائل چندمرحله ای (Multi-Hop Reasoning): ناتوانی در شکستن یک مسئله پیچیده به مراحل کوچک تر و حل ترتیبی آن ها.
- برای عبور از این محدودیت ها، مفهوم «ایجنت های هوشمند (LLM Agents)» شکل گرفته است. در معماری ایجنت، ما از مدل زبانی نه به عنوان یک دایره المعارف ساکت، بلکه به عنوان «مغز متفکر و تصمیم گیرنده» استفاده می کنیم که به ابزارهای جانبی دسترسی دارد.

هدف پروژه:

هدف این پروژه، طراحی و پیاده سازی برنامه ای به نام پژوهش یار است که باید بتواند یک «درخواست تحقیق پیچیده و چندمرحله ای» را از کاربر بگیرد و بدون دخالت انسان، با زنجیره کردن ابزارهای در دسترس، پاسخ نهایی را استخراج کند. برای درک دقیق کاری که برنامه شما باید انجام دهد، این نمونه را بررسی کنید:

- ورودی سیستم (User Input): *برنده جایزه اسکار بهترین کارگردانی در سال ۲۰۲۵ چه کسی بوده است؟ تاریخ تولد او را پیدا کنید و محاسبه کنید در زمان برگزاری جام جهانی فوتبال در سال ۲۰۲۶ او چند ساله خواهد بود؟ در نهایت، یک خلاصه ۲ جمله ای از سبک فیلم سازی او ارائه دهید.*
- مراحل عملیاتی که انتظار می رود برنامه به صورت خودکار و پشت سرهم طی کند:

۱. مرحله اول (جستجوی اولیه): برنامه باید متوجه شود که ابتدا نیاز به نام کارگردان دارد؛ پس باید به صورت خودکار عبارت مناسب را در وب جستجو کرده و نام کارگردان برنده اسکار ۲۰۲۵ را از درون متن صفحات پیدا کند.

۲. مرحله دوم (استخراج فکت): برنامه باید با داشتن نام کارگردان، به سراغ ویکی پدیا برود، صفحه بیوگرافی او را باز کند و سال تولد دقیق او را استخراج کند.

۳. مرحله سوم (محاسبه منطقی): برنامه باید سال تولد استخراج شده را برداشته و به ابزار ماشین حساب بدهد تا تفاضل آن با سال ۲۰۲۶ (زمان جام جهانی) را بدون خطای محاسباتی به دست آورد.

۴. مرحله چهارم (خلاصه سازی متن طولانی): برنامه باید متن بیوگرافی کارگردان را به ابزار خلاصه ساز بدهد تا تحلیل های طولانی را فشرده کند.

۵. مرحله پنجم (تولید خروجی نهایی): برنامه باید تمام این دیتای جمع آوری شده را در قالب یک پاسخ متنی منسجم و مرتب به کاربر برگرداند.

• خروجی نهایی سیستم (Expected Output) :

"برنده اسکار بهترین کارگردانی سال ۲۰۲۵، [نام کارگردان] است. او متولد سال [سال تولد] بوده و در زمان جام جهانی ۲۰۲۶، دقیقاً [سن] ساله خواهد بود. سبک فیلم سازی او عمدتاً با [خلاصه ۲ جمله ای] شناخته می شود".

معیار موفقیت پروژه: برنامه شما نباید در هیچ کدام از این مراحل متوقف شود یا به دلیل ندانستن اطلاعات روز یا خطای ریاضی، پاسخ اشتباه (توهم) تولید کند. سیستم باید آن قدر هوشمند باشد که اگر در هر مرحله با بن بست مواجه شد (مثلاً یک پیوند در وب باز نشد)، مسیر خود را اصلاح کرده و ابزار دیگری را امتحان کند.

مراحل انجام پروژه:

در این بخش از تکلیف، شما قرار است پله پله سیستم پژوهش یار خود را بسازید. پروژه به ۵ گام اصلی تقسیم شده است؛ در هر گام شما یک مفهوم کلیدی از دنیای ایجنت ها و فریم ورک LangChain را پیاده سازی خواهید کرد.

گام ۱: رویارویی با محدودیت‌های مدل زبانی پایه (Base LLM)

در این گام، سوال تحلیلی و چندمرحله‌ای زیر را مستقیماً به مدل زبانی خود (بدون هیچ ابزار یا فرآیند جانبی) ارسال کنید و خروجی آن را چاپ کنید:

"برنده جایزه اسکار بهترین کارگردانی در سال ۲۰۲۵ چه کسی بوده است؟ تاریخ تولد او را پیدا کنید و محاسبه کنید در زمان برگزاری جام جهانی فوتبال در سال ۲۰۲۶ او چند ساله خواهد بود؟ در نهایت، یک خلاصه ۲ جمله‌ای از سبک فیلم‌سازی او ارائه دهید."

- **نتیجه مورد انتظار:** خروجی مدل را تحلیل کنید. آیا مدل دچار توهم شده است؟ آیا سال تولد را اشتباه حدس زده یا در محاسبات ریاضی خطا کرده است؟ این نتایج را در یک بلوک متنی کوتاه گزارش کنید.

گام ۲: معرفی ابزارها به لنگ چین (Tools Definition)

شش تابع پایتونی پایه زیر را پیاده سازی کنید:

```
web_search -  
read_page -  
wikipedia_search -  
calculator -  
summarize -  
get_current_date -
```

وظیفه شما در این گام این است که با استفاده از دکوراتور `@tool` در لنگ چین، این توابع را به «ابزارهای رسمی لنگ چین» تبدیل کنید.

- نکته کلیدی: مدل زبانی کدهای پایتون را نمی‌بیند؛ او فقط نام ابزار و توضیحات ابزار را می‌خواند. شما باید توضیحات متنی (Docstring) هر ابزار را آن قدر دقیق و واضح بنویسید که مدل کاملاً متوجه شود در چه شرایطی باید آن ابزار را صدا بزند و چه ورودی‌ای به آن بدهد.
- همچنین یک ابزار هفتم به انتخاب خودتان طراحی کنید و به مجموعه ابزارهای پژوهش‌یار اضافه کنید. این ابزار به خلاقیت خود شما بستگی دارد. نحوه معرفی ابزار جدید به سیستم را مستند کنید.

گام ۳: استخراج اولین اقدام و طراحی پارسر (Single-Turn Action & Parser)

سیستم پرامپت (System Prompt) را طوری طراحی کنید که مدل با دیدن سوال کاربر، کل پاسخ را یک جا تولید نکند؛ بلکه فقط اولین قدم عملیاتی خود را در قالب یک فرمت متنی مشخص خروجی دهد. مثلاً:

Action: web_search[oscar 2025 best director]

سپس شما باید یک تابع واسطه یا Custom Parser در پایتون بنویسید که این متن خروجی را بخواند، نام ابزار و آرگومان داخل کانتینر را استخراج کند، آن را به تابع پایتونی مربوطه بفرستد و نتیجه ابزار (Observation) را دریافت کند. فرمت گفته شده را خودتان میتوانید طراحی کنید.

گام ۴: ساخت چرخه خودمختار ReAct و مدیریت حافظه (The Agent Loop)

یک حلقه هوشمند بسازید که فرآیند گام ۳ را به صورت خودکار تکرار کند. چالش اصلی این گام، مدیریت حافظه (Memory) است. شما باید در هر تکرار حلقه، «فکر مدل»، «اقدام انجام شده» و «مشاهده ناشی از خروجی ابزار» را به تاریخچه چت (Message History) اضافه کنید و دوباره به مدل بفرستید.

- نتیجه مورد انتظار: مدل باید پله پله اطلاعات را جمع کند (مثلاً نام کارگردان، تاریخ تولد، محاسبات ریاضی، خلاصه بیوگرافی). حلقه شما باید زمانی متوقف شود که مدل اعلام کند اطلاعاتش کامل است و کلمه کلیدی "Final Answer:" را به همراه پاسخ نهایی چاپ کند. برای جلوگیری از حلقه های بی انتها، حتماً سقف تعداد تکرار (مثلاً حداکثر ۵ تکرار) اعمال کنید.

گام ۵: آزمون تاب آوری و مدیریت خطای ابزارها (Robustness & Reflection)

سیستم خود را با یک سوال گمراه کننده یا یک ابزار خراب به چالش بکشید. به عنوان مثال، سوالی بپرسید که پاسخ آن در ویکی پدیا وجود ندارد و ابزار ویکی پدیا مقدار Error: Page not found را برمی گرداند. ایجنت شما نباید کرش کند یا متوقف شود؛ بلکه باید با بازنگری در پرامپت یا منطق حلقه، این خطا را مثل یک انسان تحلیل کرده، مسیرش را اصلاح کند (مثلاً به سراغ جستجوی عمومی وب برود) یا به صورت محترمانه به کاربر اعلام کند که چرا امکان حل مسئله وجود ندارد.

گام ۶: تست و تحلیل ۵ مثال

۵ مثال نمونه که تقریباً از همه toolها استفاده می کنند را طراحی کنید و با استفاده از ایجنت پژوهش یار هوشمند به سوالات پاسخ دهید و سپس نتایج را تحلیل کنید.

تمرین دوم: ساخت سیستم پرسش و پاسخ مبتنی بر اسناد

مسئله‌ی اصلی این تمرین این است که مدل‌های زبانی، به‌ویژه مدل‌های کوچک، هنگام پاسخ‌گویی به پرسش‌هایی که به محتوای دقیق یک سند وابسته‌اند، همیشه قابل اعتماد نیستند. این مدل‌ها ممکن است بدون مراجعه به متن اصلی، پاسخ‌هایی تولید کنند که از نظر زبانی درست و قانع‌کننده به نظر می‌رسند، اما با محتوای واقعی سند سازگار نیستند. این مسئله در کاربردهایی مانند پاسخ‌گویی بر اساس کتاب‌ها، مقالات، مستندات فنی و منابع آموزشی اهمیت زیادی دارد؛ زیرا در این کاربردها پاسخ باید به متن منبع متکی باشد، نه صرفاً به دانش قبلی مدل.

در این تمرین، با استفاده از چند فصل از کتاب *Speech and Language Processing* نوشته‌ی Jurafsky and Martin، یک دستیار آموزشی برای پاسخ‌گویی مبتنی بر بازیابی اسناد پیاده‌سازی می‌کنید. ایده‌ی اصلی این است که ابتدا بخش‌های مرتبط از اسناد بازیابی شوند و سپس این بخش‌ها در کنار سؤال به مدل زبانی داده شوند. در طول تمرین، عملکرد مدل در سه حالت مقایسه می‌شود: بدون بازیابی، همراه با بازیابی BM25، و همراه با بازیابی چگال. جزئیات مراحل پیاده‌سازی، بخش‌های کدنویسی، و سؤالات تحلیلی که باید به آن‌ها پاسخ دهید، در notebook تمرین آمده است.